



Portfolio

Projekt: Data Science Use Case (DLMDWPDSUC01)

im Master Studiengang Data Science

**Rettungsdienst Berliner Rotes Kreuz
MachineLearning-Einsatz in der Bereitschaftsplanung
UseCase Analyse**

Verfasser: Georg Grunsky

Matrikelnummer: IU14072015

Tutor: Thomas Zöller

Datum: 25. Februar 2025

I Abstract

Der Berliner Rot Kreuz Rettungsdienst strebt den Einsatz eines MachineLearning-Systems zur effizienten Planung eines Bereitschaftsdienstplanes für Einsatzfahrer:innen an. Diese Arbeit analysiert mit Hilfe des MachineLearning Canvas den UseCase und schafft somit die Grundlagen für eine Projektinitierung zur Implementierung des Systems.

Im Fokus der Zielvorgaben stand die Herausforderung, kosteneffizient die tägliche Anzahl des benötigten Bereitschaftspersonals vorherzusagen, gleichzeitig jedoch nie zu wenig Einsatzfahrende als Reserve vorzusehen. Für viele Aspekte der Analyse stellte das ein zentrales Thema dar. Auch die modellzentrierte Performanz der Vorhersage wird anhand einer Quantifizierung dieser Vorgaben gemessen.

Die, in dieser Arbeit beschriebene, Analyse baut auf einer bestehenden Grundlage an Zeitreihendaten der Organisation auf, spricht aber ebenso Anregungen für die Implementierung zusätzlicher Prozesse zur Optimierung der Datenakquise sowie eine mögliche Erweiterung der Datengrundlage durch Online-Daten an.

Der MachineLearning Canvas erwies sich in diesem UseCase als effektives Werkzeug zur aufgabenorientierten Strukturierung der Anforderungen. Durch die Analyse ist es möglich, mit vergleichbar geringem Arbeitsaufwand, die Eckpfeiler des Anwendungsfalles zu skizzieren und dabei die Wertschöpfung für den Bedarfsträger in den Mittelpunkt zu stellen. Durch den Einsatz einer MachineLearning-basierten Vorhersage der in Bereitschaft zu haltenden Einsatzfahrer:innen und somit einer zielgerichteten Planung dieser Humanressource, reduziert der Berliner Rot Kreuz Rettungsdienst täglich Kosten. Dieser Nutzen wird auch in der laufenden unternehmenszentrierten Performanzmessung des Modells reflektiert.

Inhaltsverzeichnis

I Abstract	II
1 Einleitung	1
2 Konzeptionsphase	2
2.1 Beschreibung des UseCase	2
2.2 Verfügbarer Datenstand und Strategie zur Behebung von Informationslücken	2
3 Reflexionsphase	4
3.1 Modell- und geschäftszentrierte Performanzmessung	4
3.1.1 KPIs im unternehmerischen Gesamtkontext	4
3.1.2 Ableitung geeigneter KPIs für den UseCase	6
3.2 Value Proposition	7
3.3 Decisions	7
3.4 Prediction Task	8
3.5 Making Predictions	8
3.6 Data Sources	9
3.7 Data Collection	9
3.8 Features	9
3.9 Building Models	11
3.10 Impact Simulation	12
3.11 Monitoring	13
4 Breakdown	14
5 Literaturverzeichnis	15
6 Abbildungsverzeichnis	16
7 Tabellenverzeichnis	17
A Annexes	18
A.1 MachineLearning-Canvas	19
A.2 PitchDeck-Präsentation	20

1 Einleitung

Im gewählten Szenario geht es um die Herausforderung, die Planungslogik des Bereitschaftsdienstplans für den Berliner Rotkreuz-Rettungsdienst zu verbessern. Das, weiter unten beschriebene, Thema ist dem Modul „Model Engineering“ des Masterstudienganges Data Science entnommen (Pak 2024), und wurde für zwei weitere Module adaptiert:

1. **Data Science UseCase:** Analyse des Anwendungsfalls bis zur Präsentation für die Freigabe durch das Management.
2. **Technische Projektplanung:** Aufbauend auf dem PitchDeck vom Projektstrukturplan über eine Kostenschätzung und das Risikomanagement bis zur Stakeholder-Analyse.
3. **Model Engineering:** Die Umsetzung des UseCase als Projekt in einem Git-Repository mit bereitgestellten Daten bis zu einem fertiggestellten Vorhersagemodel.

Die Motivation, dieses Thema auch im Modul „Data Science UseCase“ zu bearbeiten, besteht darin, die Problemstellung aus mehreren Blickwinkeln zu behandeln und so ein durchgängiges Verständnis für die Abwicklung realer Szenarien zu erlangen. Die ganzheitliche Betrachtungsweise der Thematik lässt einen tieferen Einblick in die Prozesse der Data Science entstehen, erhöht die Identifikation mit dem UseCase und macht somit schlussendlich auch mehr Spaß.

2 Konzeptionsphase

2.1 Beschreibung des UseCase

Die DRK Rettungsdienst Berlin GmbH ist Teil der Notfallrettung in Berlin und Partner des Landes Berlin. Der Dienst besetzt Rettungs- und Intensivtransportwagen und absolviert jährlich tausende Alaromeinsätze im Berliner Stadtgebiet (DRK 2024). Täglich sind hierbei mehrere Einsatzfahrende im Dienst.

Das beschriebene Szenario (Pak 2024) sieht vor, pro Tag zusätzlich 90 weitere Fahrer:innen in Bereitschaft zu halten, um bedarfsgerecht agieren zu können.

Die Planungsstelle für den Bereitschaftsdienstplan ist mit der Lösung einer fixen vorgehaltenen Anzahl an Bereitschaftsfahrenden nicht zufrieden. Meistens werden zu viele Fahrer:innen in Bereitschaft gehalten und müssen dafür natürlich auch entlohnt werden. Manchmal sind es jedoch auch zu wenige und dann muss zusätzliches Personal „durchgerufen“ und aktiviert werden. Die Planungsstelle nimmt, aufgrund von Erfahrungswerten außerdem an, dass es saisonale Unterschiede in der Menge des benötigten Bereitschaftspersonals gibt, die bisher noch nicht berücksichtigt wurden.

Der Rettungsdienst erörtert die Möglichkeiten, im Rahmen eines Projekts, eine effizientere Planung der erforderlichen Bereitschaften mit Hilfe von maschinellem Lernen zu realisieren. Daher soll vor der tatsächlichen Entscheidung über die Projektvergabe, der Anwendungsfall analysiert werden. Ziel dieser Analyse ist es, die Machbarkeit der Umsetzung des UseCases mit Methoden des DataScience zu untersuchen, möglichen Bedarf an zusätzlichen Informationen für die Umsetzung zu identifizieren und den Erfolg des Projektes messbar zu gestalten.

Als Vorgabe für einen Lösungsvorschlag im Rahmen der UseCase-Analyse wurde festgelegt, dass sich dieser nach der aktuellen Arbeitsweise der Planungsstelle richten muss. So wird zB der Bereitschaftsplan jeweils am 15. Tag des Vormonats fertiggestellt. Die Vorhersage eines maschinellen Lernmodells soll daher bereits spätestens am 10. des Vormonats den quantitativen Bedarf ermittelt haben, um dem Planungspersonal auch noch Zeit für die namentliche Besetzung des Plans einzuräumen. Außerdem soll ein dynamischer Bereitschaftsplan auch eine Schwankungsbreite berücksichtigen, sodass an keinem Tag zu wenig Bereitschaftsfahrende vorgesehen werden.

2.2 Verfügbarer Datenstand und Strategie zur Behebung von Informationslücken

Der Berliner Rotkreuz Rettungsdienst kann für die Untersuchung des Anwendungsfalls historische Daten bereitstellen, die in der Planungsstelle des Bereitschaftsplans gesammelt wurden. Die Daten wurden bereinigt und zusammengefasst, sodass keine personenbezogenen Daten enthalten sind und daher nicht weiter auf die Bestimmungen der Datenschutzgrundverordnung und des Datenschutzgesetzes Rücksicht genommen werden muss. Der Rettungsdienst nimmt den Datenschutz

sehr ernst. Nach einer Datenschutzverletzung im Mai 2019, erfolgte eine systemische Umstellung der Datenerfassung, weshalb zur UseCase-Analyse ab diesem Zeitpunkt keine jüngeren Daten mehr zur Verfügung stehen.

Die vorliegenden Daten beinhalten, über einen Zeitraum von etwa drei Jahren, eine tageweise Aufstellung folgender Werte:

- die Anzahl der Notrufe
- die Anzahl der krankgemeldeten Einsatzfahrenden
- die Anzahl der diensthabenden Fahrer:innen
- die Anzahl des Personals im Bereitschaftsdienst
- die Anzahl des aktivierten Bereitschaftspersonals
- die Anzahl an zusätzlichem benötigten Personal über den Bereitschaftsdienst hinaus

Dass die oben genannten Daten nur bis Mai 2019 erfasst wurden, ist für die Analyse des Anwendungsfalls selbst grundsätzlich kein Problem, würde jedoch zu einem späteren Zeitpunkt - in der Umsetzung - zu erheblichen Qualitätseinbußen eines Vorhersagemodells führen. Gerade in den Jahren nach 2019 haben sich einige globale Umgebungsvariablen des sozialen Zusammenlebens verändert, zB das Auftreten des „Corona-Virus“. Dadurch könnte, gerade in den hier benötigten Merkmalen, wie den Notfällen und den Krankenstandsmeldungen des Personals, ein maßgeblicher **Daten-Drift** stattgefunden haben. Wie bereits erwähnt, wird dieser Fakt den Schritt der UseCase-Analyse nicht behindern, aber das Ergebnis beeinflussen. Das Management sollte daher, bereits parallel, die Machbarkeit einer **Bereitstellung von aktuellen Daten** im Rahmen der gesetzlichen Vorschriften und Sicherheitsaspekte evaluieren. Die Analyse wird einstweilen unter der Annahme fortgesetzt, dass das Management hierbei erfolgreich sein wird.

Die Vermutung der Planungsstelle, dass die vorliegenden Daten **saisonalen Schwankungen** unterliegen, wird vermutlich einen Ansatzpunkt der UseCase-Analyse darstellen. An dieser Stelle könnte man ein Vorhersagemodell mit allen möglichen, **zusätzlichen Daten** „füttern“. Temperatur und Wetterdaten könnten zum Beispiel verwendet werden um mögliche Krankenstandsakkumulationen vorherzusagen. Feiertage und Wochentage, sowie Schulferien und „Zwickeltage“ (einzelne Tage zwischen Wochenenden und Feiertagen, die gerne frei genommen werden) könnten herangezogen werden um quantitative Unterschiede in den Notfällen aufgrund von Freizeitaktivitäten vorherzusagen, ebenso wie der Veranstaltungskalender der Stadt Berlin. Die Daten dieser Überlegungen sind grundsätzlich **online verfügbar**, die Beschaffung wäre daher kein großer Aufwand. Der Deutsche Wetterdienst stellt zB in seinem Downloadarchiv die Messwerte einzelner Stationen zur Verfügung (DWD 2024). Im Rahmen der Datenaufbereitung und Merkmalsgenerierung des Vorhersagemodells wäre allerdings noch zu evaluieren, welche dieser Daten tatsächlich einen aussagekräftigen Mehrwert für eine Vorhersage liefern und welche eher zu einer Überanpassung des Modells führen.

3 Reflexionsphase

Der MachineLearning Canvas von Dorard (2022) ist ein Werkzeug zur Bearbeitung von MachineLearning UseCases. Er unterstützt dabei, die Umgebungsvariablen des UseCase strukturiert „abzuklopfen“ und eine Planungsgrundlage für das weitere Vorgehen zu schaffen. Durch die thematische Aufteilung in mehrere Rubriken erleichtert der ML-Canvas die Zusammenarbeit im Team, da Expertisen aus verschiedenen Rollen einfach eingebracht werden können. Diesen Rubriken ist, gemäß Aufgabenstellung, im Folgenden jeweils ein eigener Punkt dieses Abschnitts gewidmet. Zuvor erläutert der erste Abschnitt dieses Kapitels aber noch geeignete Maßstäbe der Performanzmessung.

3.1 Modell- und geschäftszentrierte Performanzmessung

Für eine, der Arbeitsaufgabe entsprechende, Darstellung geeigneter modell- und geschäftszentrierter Key Performance Indicators (KPIs) in Bezug auf die Güte des gegenständlichen Vorhersagemodells ist es notwendig, vorab den Begriff KPI im Allgemeinen zu diskutieren. Annahmen über die Definition von Erfolgsfaktoren des Berliner Rotkreuz-Rettungsdienstes dienen anschließend als Grundlage für relevante Performanzmetriken des MachineLearning Modells.

Heß (2022) beschreibt die Definition von „Erfolg“ als zentralen Punkt der Evaluierung eines UseCase. Diese Definition entscheidet maßgeblich ob die Bewertung positiv oder negativ ausfällt. Dabei wird weiter unterschieden in die **modellzentrierte** und die **unternehmenszentrierte** Auswertung. Erstere gibt an, ob das Modell unbekannte oder zukünftige Ereignisse anforderungsgemäß vorhersagen kann. Die unternehmenszentrierte Bewertung eines Projekts konzentriert sich dagegen auf jene Aspekte eines UseCase, die sich auf die Organisation auswirken, in dem dieser umgesetzt wird. Es ist wichtig zu bewerten, ob sich Entscheidungen, die aus Vorhersagen resultieren, positiv oder negativ auf die Strategie der Organisation auswirken. Eine rein monetäre Bewertung ist in vielen Fällen nicht möglich, da die Entscheidungen oft von vielen Faktoren beeinflusst sind und wiederum andere Entscheidungen beeinflussen. Deshalb werden in der Praxis oft mehrere Kennzahlen (engl., Key Performance Indicators, KPIs) zur Evaluierung verwendet. (Heß 2022, S.62)

3.1.1 KPIs im unternehmerischen Gesamtkontext

Parmenter (2010) verfeinert die Aussagen von Heß (2022) und wird hier noch spezifischer. Er unterteilt die obige Darstellung vom allgemeinen Begriff KPIs weiter in Key Result Indicators (KRIs), Result Indicators (RIs), Performance Indicators (PIs) und Key Performance Indicators (KPIs). Gemeinsam mit den kritischen Erfolgsfaktoren (CSFs), sind diese auf die Mission, die Vision und auch die Werte der jeweiligen Organisation ausgerichtet. Die nachfolgende Darstellung veranschaulicht das Zusammenspiel dieser Elemente.

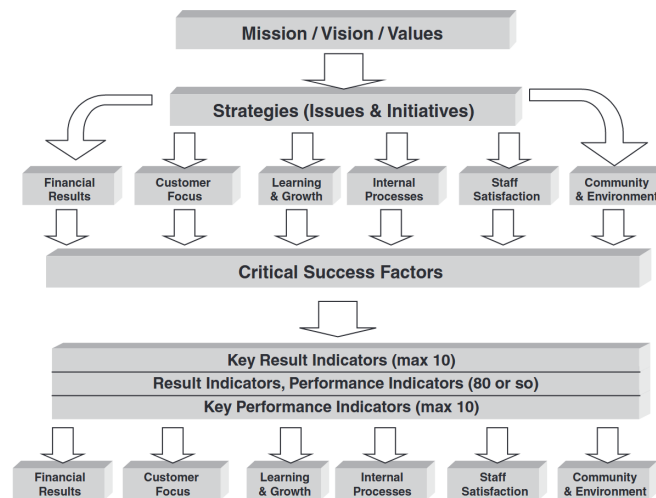


Abb. 1: Von der Mission zur Performanzmessung
(Parmenter 2010, S.35)

In der Literatur oft nicht klar zu unterscheiden sind Key Performance- und Key Result Indicators:

- **Key Result Indicators (KRIs)** inkludieren Metriken wie zB die Kundenzufriedenheit, den Gewinn, den Profit pro Kunde, oder auch Zufriedenheit des Personals. Allen KRIs ist gemein, dass sie das Ergebnis vieler Aktionen sind. Meistens decken sie eine längere Periode (zB monatlich oder vierteljährlich) ab und geben Auskunft darüber, ob man in die richtige Richtung steuert. Sie drücken also aus, was man in Bezug auf kritische Erfolgsfaktoren (CSFs) in der letzten Periode gemacht hat. Sie sagen jedoch nicht, was zu tun ist um diese Werte zu verbessern. KRIs werden oftmals mit KPIs verwechselt.
- **Key Performance Indicators (KPIs)** sind auf KRIs ausgerichtet und repräsentieren jene Maßnahmen die für den aktuellen und zukünftigen Erfolg der Organisation kritisch sind. Analog zu KRIs werden sie aus der Masse an PIs ausgewählt und stehen mit zumindest einem CSF in unmittelbarem Zusammenhang. Sie werden in hoher Frequenz überwacht, werden von der oberen Managementebene geregelt, ermutigen das Personal die richtigen Aktionen zu setzen und können nicht monetär beschrieben werden.

Parmenter (2010) verknüpft, wie bereits erwähnt, CSFs mit den sechs Perspektiven der Balanced Scorecard (BSC). Der österreichische Wirtschaftswissenschaftler Fredmund Malik erachtet die BSC als nicht ausreichend und formuliert stattdessen sechs Schlüsselgrößen für den Unternehmenserfolg (manager-magazin 2005). Hieraus werden, für die spätere Ableitung der KPIs des gegenständlichen UseCase, die nachfolgend beschriebenen exemplarisch gewählt:

- Die **Innovationsleistung**. Hierunter fallen zum Beispiel der Umsatzanteil neuer Produkte, aber auch nach innen gerichtete Innovation wie etwa eine Erneuerung von Prozessen, Technologien oder Strukturen. Fehlende, nachlassende oder fehlgeleitete Innovation beschreibt Fredmund Malik als Warnsignal erster Ordnung.
- Die **Produktivität** in all ihren Dimensionen. Die Kennziffern hierfür drücken sich in der Wertschöpfung pro Mitarbeiter, pro investierter Geldeinheit, sowie pro Zeiteinheit aus. Zukünftig wird man sich auch noch über die Definition einer Produktivität des Wissens Gedanken machen müssen. An Stelle der Idee des ständigen Wachstums tritt der Faktor einer laufenden Produktivitätsverbesserung.

3.1.2 Ableitung geeigneter KPIs für den UseCase

Abbildung 1 zeigt, dass Performance Indicators und Key Performance Indicators letztendlich aus der Unternehmensmission und den Unternehmenswerten abgeleitet werden. Die Perspektiven der Balanced Scorecard können genauso gut durch Maliks Schlüsselgrößen ersetzt werden. Entscheidend ist, in diesen Bereichen kritische Erfolgsfaktoren zu erarbeiten. Die Arbeit an Unternehmenswerten über Erfolgsfaktoren bis zur Performancemessung ist weder schnell noch einfach. Im nachfolgenden Versuch der Herleitung eines exemplarischen KPI aus geschäftszentrierter Sicht, soll dieser Weg skizziert werden. Die Beurteilung der CSF erfolgt dabei, wie oben erwähnt, beispielhaft in den Schlüsselgrößen Produktivität und Innovationsleistung.



Quelle: (DRK 2024)

Im Leitsatz und Leitbild des Landesverbandes Berliner Rotes Kreuz (DRK 2024) wird unter anderem das Verhältnis zu anderen Institutionen und Organisationen aus Staat und Gesellschaft beschrieben. Darin wird festgehalten, das sich das Berliner Rote Kreuz seine Unabhängigkeit bewahrt, sich jedoch dem Wettbewerb mit anderen stellt, indem es die Qualität und auch die Wirtschaftlichkeit der Hilfeleistung verbessert. Qualität und Wirtschaftlichkeit können in diesem Kontext als jene Werte der Organisation betrachtet werden, die zur weiteren Beurteilung herangezogen werden.

- Die **Qualität** einer Organisation ist in vielen Bereichen zu erkennen. Die Ausbildung des Personals, die Stringenz der Arbeitsprozesse, die eingesetzte Technologie, etc. sind nur einige Beispiele hierfür. Letztendlich bewertet jedoch die Wahrnehmung des Kunden ob ein Unternehmen qualitativ hochwertig arbeitet. *Steigerung der Kundenzufriedenheit* wäre eine entsprechende Strategie.
- **Wirtschaftlichkeit**: Nachdem das Rote Kreuz kein gewinnorientiertes Unternehmen ist, bedeutet wirtschaftliches Arbeiten die Einsparung unnötiger Kosten. Die Strategie lautet daher: *Steigerung der Kosteneffizienz*

Die weiteren Beurteilungsschritte werden in der nachfolgenden Tabelle 1 verkürzt dargestellt.

Wert	Qualität	Wirtschaftlichkeit
Strategie	Steigerung der Kundenzufriedenheit	Steigerung der Kosteneffizienz
Innovation	Prozessoptimierung der „time-to-target“	Kostenreduktion durch Einsatz neuer Technologien
Produktivität	schnellstmögliche Hilfeleistung	Erhöhung der Wertschöpfung pro Arbeitsstunde
CSF	Innerhalb 30 min am Einsatzort	unproduktive Arbeitsstunden minimieren
KRI	Statistische Aufbereitung der „time-to-target / no-shows“	mittlere Personalkosten pro Notruf
KPI	Fehlendes StandBy-Personal für die Bearbeitung eines Notrufs	Obergrenze für nicht aktivierte StandBy-Kosten

Tab. 1: Ableiten von KPIs aus Werten

Gemäß Parmenter (2010) sind KPIs Angelegenheit des oberen Managements und lösen auch eine Handlung beim Personal aus. In diesem Beispiel könnte zB der KPI „Fehlendes StandBy-Personal für

die Bearbeitung eines Notrufs“ einen Anruf der Planungsstelle beim Landesbereitschaftsleiter oder beim Vorstand nach sich ziehen. Ein Umstand den man als Planungspersonal unbedingt vermeiden möchte.

Unter der Annahme, dass der gegenständliche UseCase tatsächlich, wie oben dargestellt, KPIs bedient und nicht nur normale Performance Indicators, sind diese nun auch mit den geschäftszentrierten KPIs der Aufgabenstellung gleichzusetzen. Inhaltlich sind diese beiden Indikatoren wenig überraschend, wurden jedoch nachvollziehbar hergeleitet und konkretisiert. Das Vorhersagemodell wird aus unternehmerischer Sicht genau an diesen beiden Maßstäben bewertet werden.

Die modellzentrierte Bewertung der Modellgüte ergibt sich aus dem geforderten Prediction Task des UseCase. Abhängigkeiten aus der geschäftszentrierten Bewertung ergeben sich vor allem dann, wenn daraus - wie in diesem Fall - Anforderungen an eine Tendenz des Modells resultieren. Hier wird zB eine Tendenz zu *false positives*, also fälschlicherweise eingeteiltem Bereitschaftspersonal, verlangt. Eine mögliche Kostenfunktion für die Modellgüte wird im Abschnitt Impact Simulation (Punkt 3.10) erörtert.

3.2 Value Proposition

Diese Rubrik stellt, auch optisch, ein zentrales Element des MachineLearning Canvas dar. Hier werden Bedarfsträger und deren Ziele erläutert, um festzuhalten wie diese von dem MachineLearning-System profitieren. Den Bereitschaftsfahrenden kommt der UseCase in sofern zugute, dass an Tagen mit vorhergesagtem niedrigeren Bedarf auch weniger Bereitschaften zu besetzen sind. Weniger Bereitschaften bedeuten für den Rettungsdienst auch eine Kostenersparnis. Gem. DRK-Reformtarifvertrag kostet eine eingeteilte, aber nicht abgerufene zwölfstündige Bereitschaft den Rettungsdienst etwa € 165,- (Deutsches Rotes Kreuz 2023). In der bisherigen Arbeitsweise wurden einfach 90 Bereitschaftsfahrende pro Tag vorgesehen. Daraus ergeben sich **Tageskosten** in der Höhe von € 14.850,-, wenn keine Bereitschaft benötigt wird. Wichtig ist jedoch ebenfalls, dass das Risiko eines Reputationsschadens durch eine mangelhafte Bereitschaftsbesetzung (reduzierte Einsatzbereitschaft) minimiert wird. Die monetäre Hinterlegung der Bereitschaftsdienste wird im Abschnitt Impact Simulation (Punkt 3.10) noch einmal erläutert.

Für die Planungsstelle entsteht im täglichen Betrieb sogar ein zusätzlicher Aufwand, weil nun nicht mehr, wie bisher, einfach ein Fixwert angenommen und in ein unumstößliches „Dienstrad“ gegossen wird. Nun müssen die vorhergesagten Werte geöffnet, übertragen und ggf. noch angepasst werden. Auf der anderen Seite steigt das Ansehen der Planungsstelle, weil hier innovativ und effizient gearbeitet wird.

3.3 Decisions

Dieses Thema beschäftigt sich mit der Frage, in welchem Prozess aus den Vorhersagen ein Mehrwert für die Bedarfstragenden geschaffen wird. Der Berliner RotKreuz-Rettungsdienst gibt am 15. Tag jedes Monats den Bereitschaftsdienstplan für den Folgemonat an die Einsatzfahrer:innen aus. Die Umsetzung und namentliche Befüllung des Bereitschaftsplans übernimmt hierbei weiterhin das Personal der Planungsstelle. Um diese manuelle Tätigkeit kosten- und personaleffizienter zu gestalten,

liefert die Vorhersage dieses UseCases bereits in den Morgenstunden des 10. Tages jedes Monats eine tageweise Aufstellung der vorhergesagten Anzahl an Bereitschaftspersonal für den Folgemonat. Damit hat die Planungsstelle noch weitere fünf Arbeitstage Zeit, den Bereitschaftsplan im Detail umzusetzen.

Das Format der Ausgabe kann sich nach den Wünschen des Planungspersonals richten. Aus Sicht der geschäftszentrierten Modellbewertung sollte dieser Wert jedoch, zur Dokumentation, als unveränderlicher Wert (read-only) ausgegeben werden. Beurteilt die Planungsstelle den Bedarf an Bereitschaftsfahrenden, zB aufgrund eines angekündigten außerordentlichen Ereignisses, für einen bestimmten Tag anders als vorhergesagt, ist es natürlich zulässig und auch notwendig, den vorhergesagten Wert überschreiben zu können. Dieser Entscheid darf jedoch keinen Einfluss auf die Bewertung der Vorhersageergebnisse haben.

3.4 Prediction Task

In diesem Bereich wird skizziert um welche Aufgabe des maschinellen Lernens es sich handelt und was die gewünschten Ergebnisse einer Vorhersage sein sollen. In diesem Fall handelt es sich um eine Regressionsaufgabe. Auf Basis von tageweisen Zeitreihendaten mit vermuteten saisonalen Schwankungen, soll der numerische Wert vorhergesagt werden, wie viele Bereitschaftsfahrende pro Tag benötigt werden. An dieser Stelle ist gedanklich mitzunehmen, dass eine zu niedrige Schätzung in jedem Fall vermieden werden soll. Diesem Umstand muss in der späteren modellzentrierten Bewertung der Anwendung unbedingt Rechnung getragen werden, da er wesentliche Auswirkung auf die Modellierung hat.

Der Dateninput besteht aus vorliegenden historischen Daten, wobei die laufende Akquise neuer Daten realistisch ist.

3.5 Making Predictions

Wann müssen Vorhersagen bereitgestellt werden, und wie viel Zeit bleibt für die Datenaufbereitung und die Berechnungen? Das DRK Berlin hat in diesem Fall keinen Bedarf an einer Echtzeitvorhersage. Modelltraining und Vorhersage finden am Anfang jedes Monats statt und müssen bis zum 10. Tag des Monats abgeschlossen sein. Das sind, im schlechtesten Fall, sechs Arbeitstage.

Wurde veranlasst, dass die richtigen Daten bereits laufend in digitaler, maschinenverarbeitbarer Form an der richtigen Stelle abgelegt werden. Ist die Zeit für eine gegebenenfalls minimale Aufbereitung kaum noch relevant. Auch der Download von möglichen zusätzlichen Daten, ob manuell oder automatisch, lässt sich leicht in einem Arbeitstag erledigen. Das, möglicherweise etwas zeitaufwendigere, Training kann automatisiert (auch am Wochenende) gestartet werden, sobald die Daten aller Tage des Vormonats sowie mögliche zusätzliche Daten bereitstehen.

3.6 Data Sources

„Data Sources“ behandelt, wie der Name bereits verrät, die Datenherkunft. In diesem speziellen Fall, liegen die Daten für eine Vorhersage bereits alle beim DRK Berlin selbst auf, bzw. können dort erhoben werden. Externe Quellen sind grundsätzlich nicht notwendig, könnten jedoch das Modell verfeinern.

Die täglichen Protokolle der tatsächlich benötigten Einsatzfahrer:innen dienen als Quelle für das Vorhersagemodell. Diese Protokolle sind im besten Fall digital verfügbar, oder müssen für das erste Training digitalisiert werden. Gleichzeitig sollte ein Prozess initiiert werden, der diese Aufzeichnungen in Zukunft digital verarbeitbar macht.

Mögliche zusätzliche Daten für eine weitere Anreicherung des Vorhersagemodells, wie in Punkt 3.8 angeführt, sind online verfügbar.

3.7 Data Collection

Der Punkt „Data Collection“ beschreibt die Strategie der Datenakquise. Diese umfasst sowohl die Beschaffung des initialen Datensatzes als auch Überlegungen zu den Parametern der Datenaktualisierung. Für den gegenständlichen UseCase ist ein initiales Datenpaket der Planungsstelle mit veralteten Zeitreihendaten, über einen Zeitraum von etwa drei Jahren, vorhanden. Dieser Datensatz kann für das Training, auf zeitlicher Basis in Trainings und Testdaten aufgeteilt werden. Um die Genauigkeit zu erhöhen ist eine zeitbasierte Kreuzvalidierung bei diesen Daten womöglich zielführend.

Eine Schwachstelle des initialen Datensatzes ist mit Sicherheit das Alter der Aufzeichnungen. Es kann sehr wahrscheinlich von einem Datendrift, seit Erhebung dieser Daten, ausgegangen werden. Es scheint daher sinnvoll, in periodischen Abständen (zB am Ende jedes Monats) ein „Retraining“ des Modells vorzunehmen und dabei jüngere Daten, je nach eingesetztem Algorithmus, ggf. höher zu Gewichten um Trends besser zu erkennen. Die tagesaktuelle Erhebung der notwendigen Daten im eigenen Unternehmen ist, aus technischer Sicht, in jedem Fall möglich. Der Prozess dazu muss jedoch erst geschaffen werden.

Eine automatische Akquise und Bereitstellung der zusätzlichen Online-Daten muss, am besten direkt vom Projektteam, geprüft werden. Werden diese Daten als ausreichend relevant für die Vorhersagegenerierung beurteilt, sollte auch hier ein Prozess geschaffen werden, der diese Daten der Planungsstelle zur Verfügung stellt. In diesem Fall wird ebenso die Verantwortung über die Datenakquise noch zu regeln sein. Auch wenn eine Automatisierung der Beschaffung durch das Projektteam realisierbar ist, so muss dieser Prozess laufend in seiner Funktion überwacht werden. Diese Aufgabe fällt wahrscheinlich der Planungsstelle zu.

3.8 Features

Die „Features“ spiegeln jene Merkmale der verfügbaren Daten wider, die für ein Vorhersagemodell herangezogen werden können. Durch Featurizing generierte zusätzliche (bzw. stellvertretende) Merkmale können zum aktuellen Zeitpunkt noch nicht angeführt werden, da hierfür noch eine eingehende Datenanalyse notwendig ist. Zur Verfügung stehen, in diesem Anwendungsfall, Daten aus täglichen

administrativen Aufzeichnungen aus der Organisation von Einsatzfahrten. Dies umfasst, wie bereits in Punkt 2.2 angeführt:

- die Anzahl der Notrufe
- die Anzahl der krankgemeldeten Einsatzfahrenden
- die Anzahl der diensthabenden Fahrer:innen
- die Anzahl des Personals im Bereitschaftsdienst
- die Anzahl des aktivierten Bereitschaftspersonals
- die Anzahl an zusätzlichem benötigten Personal über den Bereitschaftsdienst hinaus

Hierzu können aus Online-Quellen weitere Features auf Tagesbasis hinzugefügt werden:

- **Durchschnittliche Tagestemperaturdaten aus dem Raum Berlin:** Diese Daten in die Vorhersage mit einzubeziehen, könnte dabei helfen, die Theorie saisonal bedingter Schwankungen durch ein weiteres Feature zu stützen. Möglicherweise lässt sich die Saisonalität besser an der durchschnittlichen Außentemperatur festmachen, als schlichtweg an Monatsnamen.
- **Weitere Wetterdaten:** Denkbar wäre auch die Untersuchung logischer Wetterfeatures wie zB eisig, Starkregen oder wolkenlos und mehr als 25°C. Die Idee hierbei ist, dass das Verhalten der Bevölkerung an diesen besonderen Tagen möglicherweise Auswirkung auf eine Unfallwahrscheinlichkeit und damit auf einen Notruf haben kann. Der Einsatz dieser Daten ist jedoch in einer ersten Version des Modells unrealistisch, da für zum Zeitpunkt der Vorhersage keine validen Wetterprognosen des nächsten Monats bereitstehen. Außerdem besteht hier die größte Gefahr einer Überanpassung des Modells. Dennoch werden diese Überlegungen für eine Folgeversion der Vorhersage mitgenommen. Vorstellbar wäre zB eine laufende Selbstevaluierung der getätigten Vorhersagen des Modells durch einen weiteren MachineLearning Ansatz unter Einbeziehung dieser logischen Wettermerkmale und auch der Prognose für zB die nächste Woche. Wenn das Modell feststellt mit den initialen Berechnungen der nächsten Woche falsch gelegen zu sein, kann das Planungspersonal mit einer Notification veranlasst werden kurzfristig, aber immer noch vorausschauend den Stand des Bereitschaftspersonals für diesen Tag zu erhöhen. Diese Folgeversion bietet Material für eine zweite UseCase-Analyse, wenn der gegenständliche UseCase erfolgreich implementiert wurde.
- **Wochen- und Feiertage:** Der Gedanke zur Berücksichtigung des Wochentages ist einfach. An Tagen, an denen Menschen tendenziell nicht ihrem beruflichen, gewohnten Tagesablauf folgen, besteht eine erhöhte Wahrscheinlichkeit eines Unfalls. Seien es sportliche Aktivitäten, oder handwerkliche Manipulationen im eigenen Haushalt, das Verhalten der Menschen an diesen Tagen hebt sich von der Norm ab. Das gilt es zu berücksichtigen. Vermutlich ist es ausreichend, das Feature nur mit einen logischen Wert zu hinterlegen, ob es sich bei diesem Tag um ein Wochenende oder einen Feiertag handelt.
- **Geplante Veranstaltungen im Raum Berlin:** Große Veranstaltungen stellen für Rettungsdienste oft eine Herausforderung dar, bei der zusätzliches Personal in Bereitschaft gehalten werden muss. Der Einfachheit halber könnte zB ein kategorischer Wert dieses Feature spezifizieren. Zum Beispiel könnte „0“ für keine Veranstaltung, „1“ für eine Veranstaltung mit mehr als 5.000 Personen, „2“ für eine Veranstaltung mit mehr als 20.000 Personen, usw. stehen. Vermutlich ist es leichter, diese Daten durch das Planungspersonal manuell recherchieren und ablegen zu lassen. Erstens müsste anderenfalls ein weiteres MachineLearning Modell ggf. die Größe der Veranstaltung abschätzen, zweitens ist es für die Planungsstelle von Vorteil sich mit anstehenden, möglicherweise einsatzrelevanten Events zu beschäftigen. Historische Eventdaten

werden wahrscheinlich nur zeit- und kostenaufwendig zu recherchieren sein. Bei dem gegenständlichen Vorhersagemodell ist vorgesehen, der Planungsstelle die manuelle Anpassung der berechneten Werte zu ermöglichen. Diese tragen schlussendlich auch die Verantwortung für den Bereitschaftsplan. Es ist daher möglich, ab dem Einsatzzeitpunkt des Modells, kategorisierte Veranstaltungen in der manuellen Dokumentation und Anpassung so zu vermerken, dass sie in Zukunft in das Berechnungsmodell mit einfließen können.

Eine Erweiterung um diese zusätzlichen Merkmale muss in jedem Fall in der Datenanalyse und im Featurizing geprüft werden. Schließlich sollen nur jene Daten mit der größten Aussagekraft für eine Vorhersage herangezogen, und ein Übertraining vermieden werden.

3.9 Building Models

Dieser Platz auf dem MachineLearning Canvas bietet die Möglichkeit, Überlegungen zum Vorhersagemodell festzuhalten. Beim Beispiel DRK Berlin handelt es sich um ein Modell, das initial auf der Basis von etwa drei Jahren Zeitreihendaten aufgebaut ist, und Anfang jedes Monats mit neuen Daten erweitert wird. Dabei wird immer über den gesamten vorhandenen Daten-Zeitraum trainiert, da die Muster schließlich in saisonalen Schwankungen gefunden werden sollen. Es wird daher ein monatliches Training des Modells angestrebt. Eine zeitkritische Einschränkung für die erste produktionsreife Implementierung des Modells wurde bei dieser Entwicklung nicht vorgegeben.

Eine erste Liste, in Frage kommender, Algorithmen für die gegenständliche Aufgabe wird nachfolgend, auf Basis einer Konversation mit ChatGPT (2024) über Möglichkeiten und Vorzüge diverser MachineLearning Algorithmen zur Vorhersage in Zeitreihen, vorgeschlagen.

- **Long Short-Term Memory (LSTM) Netzwerke** sind eine spezielle Art von rekurrenten neuronalen Netzwerken, die sich gut eignen, wenn Daten starke zeitliche Abhängigkeiten oder saisonale Muster aufweisen.
- **Facebook Prophet** wurde speziell für Zeitreihenvorhersagen entwickelt, unterstützt automatisch verschiedene Saisonalitäten und ist robust gegen plötzliche Änderungen und fehlende Daten. Prophet erfordert weniger manuelle Anpassungen als neuronale Netze.
- **Random Forest Regressor** sind robust gegenüber Überanpassung und können komplexe nichtlineare Beziehungen in Daten erfassen. Sie sind jedoch nicht explizit für die Modellierung von zeitlichen Abhängigkeiten geschaffen.
- **Seasonal Autoregressive Integrated Moving Average (SARIMA)** ist ein klassisches Modell für saisonale Zeitreihenanalysen. Das Modell ist gut interpretierbar und eignet sich vor allem für stark autoregressive Daten mit wenig externen Einflussgrößen
- **XGBoost/LightGBM** sind leistungsfähige Gradient Boosting-Algorithmen, die oft schneller und skalierbarer sind als neuronale Netze. Sie benötigen jedoch ein explizites Feature-Engineering um die Zeitkomponente der Daten zu modellieren.
- **Temporal Fusion Transformer (TFT)** kann sowohl lange als auch kurze zeitliche Abhängigkeiten in Zeitreihendaten erfassen. TFT eignet sich gut für komplexe zeitliche Muster mit einer großen Anzahl von Features.

Die Vorteile hinsichtlich der Modellierung komplexer zeitlicher Muster überwiegen bei LSTM, TFT oder XGBoost/LightGBM, wo hingegen die Stärken von SARIMA und Prophet vor allem in der

Interpretierbarkeit einfacher Zeitreihen liegen. In einer ersten Beurteilung scheint „Facebook Prophet“ den Anforderungen dieses UseCase gut entgegenzukommen. Dieser Algorithmus verwendet ein zusammengesetztes Modell, dessen drei Hauptkomponenten den allgemeinen Trend, die Saisonalität sowie Feiertage und spezielle Ereignisse in Zeitreihen berechnen (Taylor / Letham 2017, S.7). Bei Letzterer kann durch den Analysten selbst eine Liste mit vergangenen, aber auch zukünftigen, Ereignissen bereitgestellt werden (Taylor / Letham 2017, S.12). Außerdem ist die Implementierung in vorrangig verwendeten Programmiersprachen wie Python oder R einfach umzusetzen.

An dieser Stelle der UseCase Analyse ist es hilfreich, den Rahmen möglicher Vorhersagemodelle abzustecken um dem anschließenden Projektmanagement eine Grundlage für die Aufwandsabschätzung der Implementierung zu bieten. Die eingehendere Beurteilung der Anwendbarkeit einzelner Algorithmen und auch der Vergleich und die Bewertung der gelieferten Ergebnisse verschiedener Modelle ist jedoch eine Aufgabe der Umsetzung des UseCase. Hier wird die endgültige Entscheidung über das verwendete Vorhersagemodell getroffen.

3.10 Impact Simulation

Unter den Punkt „Impact Simulation“ fallen Überlegungen zur Bewertung des Vorhersagemodells vor einer Inbetriebnahme. In diesem Anwendungsfall werden, zum Beispiel, die tatsächlichen, täglichen Bereitschaftsfahrten des Test-Datensatzes mit der Vorhersage aus den Trainingsdaten verglichen. Die Performance wird gemessen an den Kosten, die für überschüssiges Bereitschaftspersonal angefallen wären, sowie am geschätzten Risiko und Aufwand zusätzliches Personal an jenen Tagen zu aktivieren, an denen die Berechnung eine zu geringe Bereitschaftsstärke vorhergesagt hätte. Nachdem ein mangelnder Bereitschaftspersonaleinsatz unbedingt vermieden werden soll, werden letztere Metriken in den Tests auch höher bewertet. Eine monetäre Hinterlegung der geschätzten Kosten muss vermutlich aus dem Bereich des Risikomanagements bereitgestellt werden, eine überschlagene Schätzung für eine erste Bewertung des Vorhersagemodells kann jedoch bereits anhand des DRK-Reformtarifvertrags erfolgen.

Ein Kraftfahrer des Deutschen Rot Kreuz Rettungsdienstes (Entlohnungsgruppe 4) verdient in der niedrigsten Entgeltstufe € 2.767,69 brutto (Deutsches Rotes Kreuz 2023). Das entspricht, bei 20 Arbeitstagen, einem Stundenlohn von etwa € 18,- brutto. Bereitschaftsdienste werden nur zur Hälfte als Arbeitszeit berechnet, erhalten jedoch gemäß §13 des Reformtarifvertrages einen 25%igen Zuschlag. Ein zwölf Stunden Bereitschaftsdienst kostet also etwa € 135,- plus den Arbeitgeberanteil der Sozialangaben, der in Deutschland noch einmal zwischen 21% und 23% ausmacht. Das sind, für den Rettungsdienst, insgesamt geschätzte Kosten in der Höhe von € 165,- pro Bereitschaftsfahrer:in, wie bereits im Abschnitt Value Proposition (Punkt 3.2) angeführt. Bisher wurde der Einfachheit halber durchgehend ein Bereitschaftsdienst von 90 Bereitschaftsfahrenden vorgesehen. Das sind für den Rettungsdienst **tägliche** Kosten in der Höhe von € 14.850,-, die ggf. nicht abgerufen werden. Die Monatskosten für, vom Vorhersagemodell avisierte aber nicht abgerufene, Bereitschaftsfahrten können beim Testen der generierten Modelle als direkter Wert für den Vergleich der Güte herangezogen werden. Das Risiko der Unterbesetzung ist monetär schwer auszudrücken. Das ist aber auch nicht notwendig, da es sich hierbei nahezu um ein K.O. Kriterium handelt. Ein deutlich überhöhter Strafbetrag (zB € 500.000,-) für jeden Tag an dem zusätzliche Bereitschaftsfahrende aktiviert werden müssen trägt diesem Kriterium Rechnung. Die Modellgüte drückt sich schlussendlich als Minimierung der

zusammengesetzten Modellkosten aus.

Die namentliche Belegung des Bereitschaftsplans erfolgt auch in Zukunft weiterhin durch Personal. Es gibt auf maschineller Seite daher keine Fairness constraints.

3.11 Monitoring

Dieser Bereich umfasst die Beschreibung von Metriken, die den Wert der Vorhersage und den Einfluss des MachineLearning UseCase auf die Planung der Bereitschaftsdienste quantifizieren. Die Arbeitsweise und der Erfolg des Systems kann, und soll, anhand dieser Metriken überwacht werden. Für das Monitoring des Modells werden an dieser Stelle jedoch nicht die geschäftszentrierten KPIs herangezogen, die im Abschnitt 3.1.2 festgelegt wurden, sondern die KRIs, also die Key Result Indicators ausgewertet. Anhand dieser Messungen erkennt man rasch eine Verbesserung der jeweiligen Werte im Vergleich zu jener Zeit vor Einsatz des Modells.

Die erarbeiteten KRIs waren:

- Eine statistisch Aufbereitete Messung der „time-to-target“ , also der Zeit vom Anruf bis zum Eintreffen am Einsatzort bzw. der „no-shows“ , das sind Notrufe, die nicht bedient werden konnten. Natürlich hängen diese Werte von viel mehr Faktoren ab, als den verfügbaren Bereitschaftsfahrer:innen. Die Vermeidung von Totalausfällen (no-shows) aufgrund mangelnden Bereitschaftspersonals wird aber eine wesentliche Ziffer für den Erfolg des Modells darstellen.
- Die mittleren Personalkosten pro Notruf sollten mit einer akkuraten Planung der Bereitschaftsfahrenden merkbar abnehmen. Wenn man den o.a. Wert als K.O.-Kriterium für die Modellbewertung erachtet, so sagt dieser Wert (im Vergleich mit Vorangegangenen) aus, wie präzise das Modell arbeitet.

Selbstverständlich können, in der ergebnisgetriebenen Entwicklung des Modells, noch weitere Metriken und Werte ausfindig gemacht werden, die eine erfolgreiche und effizienzfördernde Arbeit des Systems aussagekräftig überwachbar machen.

4 Breakdown

Ausgangspunkt dieser Arbeit war ein MachineLearning Szenario, das einem anderen Modul dieses Studienganges entnommen wurde. Dank der Zustimmung der zuständigen Tutoren wurde es möglich, dasselbe Thema in drei unabhängigen aber inhaltlich dennoch aneinander anschließenden Modulen zu bearbeiten. So bekommt der UseCase mehr Gestalt, erfordert überlegtes Vorgehen (um Nachfolgeschritte zu erleichtern) und erzielt einen synchronisierten Lerneffekt in Bezug auf den Gesamtprozess einer MachineLearning-Systemimplementierung. Eine Herausforderung, die dankbar angenommen wurde.

Bei der Bearbeitung eines realitätsnahen Szenarios über einen längeren Zeitraum, zählt es sich ebenso aus, neue Werkzeuge zur Umsetzung auszuprobieren. Für den UseCase wurde daher ein Git-Repository angelegt und einem Git-Projekt hinzugefügt. Die zeitliche Planung und die Tasks dieser Aufgabenstellung wurden in Form von Iterations, Meilensteinen und Issues über das Git-Projekt abgewickelt. Gleichzeitig wurde über das Repository die Versionskontrolle der LATEX-Dateien dieser Arbeit sichergestellt. Die beiden nachfolgenden Studienmodule sollen ebenfalls über dieses Git-Projekt (aber in jeweils eigenen Repositories) bearbeitet werden.

Für die inhaltliche Ausarbeitung lieferte der MachineLearning Canvas einen guten, strukturierten Anhalt. Erste Überlegungen wurden hierbei initial im OnePager (siehe Anhang A.1) notiert und erst danach im Hauptdokument ausformuliert und gegebenenfalls durch Literatur- oder Onlinerecherche vertieft. Die abschließende Überarbeitung der Initialversion des OnePagers diente zugleich als Reflexion der ursprünglichen Gedanken zum UseCase.

Die Rückmeldung zu den eingereichten Zwischenergebnissen dieser Prüfungsform waren absolut konstruktiv, klar verständlich und eine wertvolle Unterstützung. Die iterative Vorgehensweise unterstützt einerseits die Vermittlung der Lerninhalte und schafft andererseits ein nachhaltiges Endprodukt, das auch als Referenz für zukünftige Aufgaben genutzt werden kann.

5 Literaturverzeichnis

ChatGPT (2024): *Gespräch über Zeitreihenanalyse und Modellierung mit Facebook Prophet.*

Deutsches Rotes Kreuz (2023): *DRK-Reformtarifvertrag.*

Dorard, L. (2022): *Machine Learning Canvas.*

DRK (2024): *Rettungsdienst - DRK LV Berliner Rotes Kreuz e.V.*

<https://www.drk-berlin.de/angebote/bevoelkerungsschutz-und-rettung/rettungsdienst.html>.

DWD (2024): *Wetter und Klima - Deutscher Wetterdienst - Leistungen - Klimadaten Deutschland.*

<https://www.dwd.de/DE/leistungen/klimadatendeutschland/klimadatendeutschland.html>.

Heß, P. D. C. (2022): *Use Case und Evaluierung.*

manager-magazin (2005): *Die Malik-Kolumne: Die Sechs Schlüsselgrößen Des Unternehmenserfolges.*

Pak, M. (2024): *Aufgabenstellung_DLMDWME01.*

Parmenter, D. (2010): *Key Performance Indicators: Developing, Implementing, and Using Winning KPIs.* John Wiley & Sons, Hoboken, N.J, 2nd ed edition.

Taylor, S. J./ Letham, B. (2017): *Forecasting at scale.*

6 Abbildungsverzeichnis

1 Von der Mission zur Performanzmessung 5

7 Tabellenverzeichnis

1 Ableiten von KPIs aus Werten 6

A Annexes










A.1 MachineLearning-Canvas

THE MACHINE LEARNING CANVAS


Designed for: Bereitschaftsplan

Designed by: Georg Grunsky

Date: 25.11.2024 Iteration: 1

<div> <div>PREDICTION TASK</div> <div>  <p>Regression in der Ermittlung der täglichen Anzahl an benötigten Bereitschaftsfahrern für den Folgemonat auf Basis von vmtl. saisonalen, numerischen Zeitreihendaten. Eine zu niedrige Schätzung muss unbedingt vermieden werden. Es stehen Daten zur Verfügung. Neue Daten können täglich akquiriert werden.</p> </div> </div>	<div> <div>DECISIONS</div> <div>  <p>Am 10. jedes Monats wird der, für den Bereitschaftsplan zuständigen, Planungsstelle eine Liste der tageweisen benötigten Anzahl an Personal im Bereitschaftsdienst für den Folgemonat ausgegeben.</p> </div> </div>	<div> <div>VALUE PROPOSITION</div> <div>  <p>Ziel: Einem Verhalten von unnötig vielen Bereitschaftsfahrern wird vorgebeugt. Gleichzeitig wird sichergestellt, dass auch nicht zuwenig Personal in Bereitschaft ist.</p> <p><u>Bedarfsträger:</u> Die Kostenplanung, die Bereitschaftsplanung und das Bereitschaftspersonal des DRK Berlin</p> <p><u>Umsetzung:</u> Vorhersagen werden aufgrund von (vmtl.) saisonalen Zeitreihendaten getroffen. Die Signifikanz wird den Anforderungen entsprechend so gesetzt, dass eine zu geringe Schätzung vermieden wird.</p> </div> </div>	<div> <div>DATA COLLECTION</div> <div>  <p>Der vorliegende Datensatz besteht aus etwa drei Jahren Zeitreihendaten. Eine Aufspaltung in Train- und Testdaten erfolgt auf zeitlicher Basis. Auch eine zeitbasierte Kreuzvalidierung ist möglich. Retraining des Modells kann am Ende jedes Monats für den Entsprechenden Zeitraum (ggf. bei höherer Gewichtung jüngerer Daten) erfolgen. So werden Trends nicht „verschlafen“</p> </div> </div>	<div> <div>DATA SOURCES</div> <div>  <p>Die Daten für eine Vorhersage liegen alle beim DRK Berlin selbst auf. Hier werden die täglichen Notfälle genauso erhoben wie die tägliche Anzahl der tatsächlich eingesetzten Bereitschaftsfahrer: innen. Mögliche zusätzliche Daten für eine weitere Anreicherung sind online verfügbar. Eine automatische Aquisierung und Bereitstellung werden geprüft.</p> </div> </div>
<div> <div>IMPACT SIMULATION</div> <div>  <p>Zum Testen der Performance wird die Modellgüte als Minimierung der Modellgesamtkosten ausgedrückt. Diese setzen sich aus Kosten für nicht abgerufene Bereitschaften und Strafbeträgen für Mangelbesetzung zusammen.</p> <p>Die namentliche Belegung des Bereitschaftsplans erfolgt durch Personal. Es gibt auf maschineller Seite daher keine Fairness constraints.</p> </div> </div>	<div> <div>MAKING PREDICTIONS</div> <div>  <p>Es besteht kein Bedarf an einer Echtzeitvorhersage. Modelltraining und Vorhersage finden am Anfang jedes Monats statt und müssen bis zum 10. Tag des Monats abgeschlossen sein.</p> </div> </div>	<div> <div>BUILDING MODELS</div> <div>  <p>Das erste Modell wird auf Basis der Daten von drei Jahren erstellt. Update des Modells: Anfang jedes Monats</p> <p>Für die erste Implementierung gibt es keine kritische zeitliche Einschränkung.</p> </div> </div>	<div> <div>FEATURES</div> <div>  <p>Tägliche Anzahl der Notfälle, Krankstände des Personals, diensthabende Fahrer:innen, Personal im Bereitschaftsdienst, aktiviertes Bereitschaftspersonal, zusätzlich benötigtes Personal.</p> <p>Weitere mögliche Onlinequellen bieten: Temperatur- und Wettervorhersagen, Wochen- und Feiertage, Veranstaltungskalender, etc.</p> </div> </div>	
<div> <div>MONITORING</div> <div> <p>Eine statistische Aufstellung der „no-shows“ bei Notrufen aufgrund fehlendem Bereitschaftspersonal im Vergleich zu vorangegangenen Werten.</p> </div> </div>			<div> <p>Die mittleren Personalkosten pro Notruf im Vergleich zu vorangegangenen Werten</p> </div>	

A.2 PitchDeck-Präsentation

iu
INTERNATIONALE
HOCHSCHULE

Portfolio


GEORG GRUNSKY

USE CASE - ANALYSE

KOSTENOPTIMIERUNG

IN DER BEREITSCHAFTSPLANUNG

TULLN, 04. Dezember 2024

iu
INTERNATIONALE
HOCHSCHULE

AGENDA

Tausende Euro pro Tag gespart!

Prozessunterstützung durch maschinelles Lernen

Details der Umsetzung

Die Projektentscheidung

01

02

03

04

04.12.2024 2

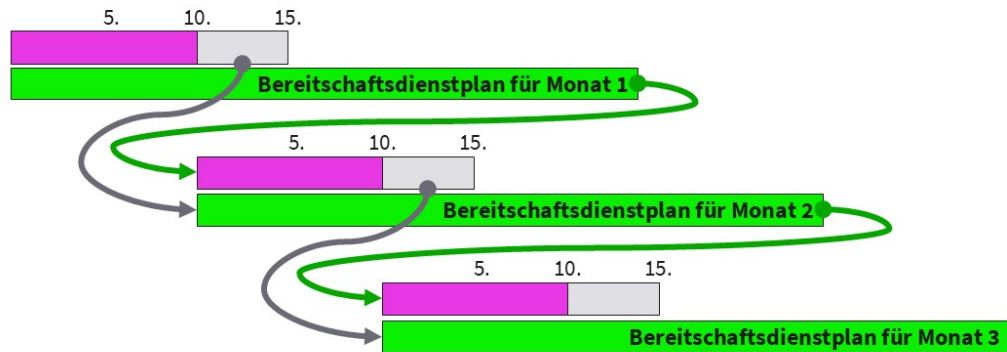
TAUSENDE EURO PRO TAG GESPART!

- 1 90 FAHRER:INNEN/TAG IM STANDBY
KOSTEN CA. €14.000,- PRO TAG
- 2 MEISTENS WIRD STANDBY-PERSONAL **NICHT ABGERUFEN**
- 3 DAS **ERHÖHT** DIE MITTLEREN
PERSONALKOSTEN PRO NOTRUF
- 4 **MASCHINELLES LERNEN** KANN IN DIESEM
ANWENDUNGSFALL DIE **EFFIZIENZ STEIGERN**
- 5 ES WERDEN **TAUSENDE EURO PRO TAG EINGESPART**

PROZESSUNTERSTÜTZUNG DURCH MASCHINELLES LERNEN (UseCase)



DETAILS DER UMSETZUNG



Legende:

- Datenerfassung
- **Vorhersage für das Folgemonat**
- Manuelle Finalisierung

Vorgaben	Monitoring
So wenig Bereitschaftsfahrende wie möglich	Personalkosten pro Notruf
Niemals zu wenig Bereitschaftsfahrende	Zeit bis zum Einsatzort / „no shows“

04.12.2024 5

DIE PROJEKTENTSCHEIDUNG



Alles bleibt wie es ist	Neue, angepasste, Arbeitsprozesse
Kein Erkenntnisgewinn	Berücksichtigung von saisonalen Schwankungen (Datenkenntnis)
Hohe Standby-Kosten (ggf. €14.000,-/Tag)	Bedarfsorientierte Planung – der Personalaufwand pro Notruf sinkt
	Systemische, manuelle Kontrolle in der Finalisierung des Dienstplanes
	Einsatz von „State of the Art“ Technologie kann durch PR-Abteilung vermarktet werden

04.12.2024 6

DANKE

Am Mittergwendt 4/8
3430 Tulln an der Donau
Niederösterreich, ÖSTERREICH

Georg Grunsky
☎ +43 660 395 94 82
✉ georg.grunsky@iu-study.org